

Qual a proporção de casos de Covid-19 no RS?

Prevalência de Covid-19 no RS com amostra aleatória e informação populacional.

Idéia geral

Considere duas quantidades de interesse:

- N_y : o número de casos já confirmados no RS.
- N_x : o número real de casos no RS.

Autoridades e pesquisadores gostariam de conhecer o número verdadeiro de casos da doença N_x , para uma população de tamanho N . Geralmente governos e órgãos responsáveis por testes conseguem divulgar somente o valor de N_y . Suponha que $N_y \leq N_x$ e que N_y seja conhecido, algumas razões para isso são discutidas em (ref.).

Se todas as quantidades definidas acima fossem observadas poderíamos apresentar os dados na forma de uma tabela 2×2 como essa abaixo.

Casos Reais	Não confirmados	Casos confirmados	\sum
Não	???	???	$N - N_x$???
Sim	???	???	N_x ???
\sum	$N - N_y$	N_y	N

Proporções de casos em populações finitas podem ser representadas por probabilidades. Primeiramente defina as variáveis aleatórias:

- Y : indicadora de caso já confirmado no RS ($Y = 1$).
- X : indicadora de casos real no RS ($X = 1$).

Assim a proporção de casos reais da doença, N_x/N , pode ser escrita como a probabilidade de uma pessoa na população ser um caso real, $\pi = P(X = 1)$. A proporção de casos já confirmados N_y/N , representa a probabilidade de uma pessoa ser um caso confirmado, $\rho = P(Y = 1)$. Suponha que $\rho \leq \pi$ (ref.).

Como calcular π ?

1. Estatísticas oficiais?

Devido a quantidade limitada de testes (em situações de emergência), geralmente os casos são detectados apenas em unidades da população em estado grave que procuram atendimento, pessoas que pertencam a grupos de risco, profissionais de saúde, ou algum outro critério de prioridade. O que provavelmente não representará a proporção real de casos na região de interesse.

2. Testar toda a população do RS?

Inviável! (Impossível seja pelo custo ou tempo, não eficiente, ...)

3. Estimar π através de uma amostra aleatória?

Se coletarmos uma amostra aleatória de tamanho n da variável X , $\mathbf{x} = (x_1, \dots, x_n)$, podemos calcular a proporção amostral

$$\hat{\pi} = \frac{\sum_{u=1}^n x_u}{n} = \frac{n_x}{n}.$$

E se também observamos Y para cada unidade?

- Utilizando informações amostrais que representem as contagens no interior da tabela acima conseguimos estimar π com maior eficiência (ref.). Como?

Na amostra teríamos a tabela

Casos Reais	Não confirmados	Casos confirmados	\sum
Não	$n - n_x$	0	$n - n_x$
Sim	$n_x - n_y$	n_y	n_x
\sum	$n - n_y$	n_y	n

Obs.: Pesquisadores ainda podem ter interesse em quantificar a proporção da diferença entre as duas probabilidades, ou seja, desejam estimar uma quantidade μ tal que $\pi = \mu \times \rho$.

Obs. 2: Nesse caso precisaremos conhecer ρ . Sabemos o valor de ρ ? Se assumirmos ρ conhecido (quando o número de casos detectados são precisamente considerados corretos. . .

Obs. 3: Conhecendo ρ , um estimador para μ pode ser dado por $\hat{\mu} = \frac{\hat{\pi}}{\rho} = \frac{n_x}{n\rho}$, se estimarmos $\hat{\pi} = n_x/n$, a proporção amostral de casos reais.

No caso do RS

Estimativas do governo indicam $\pi = ?$. Qual o estimador utilizado? (media amostral?) Assumindo uma população de $N = 113.000.00$ habitantes no RS (ref.). . . Informacoes oficiais dizem que existem $Y = 348$ casos confirmados na população do RS. . .

Fase 1 Populacao

Casos Reais	Não confirmados	Casos confirmados	\sum
Não	???	0	
Sim	???	???	
\sum	111.299.616	384	11.300.000

Amostra

Casos Reais	Não confirmados	Casos confirmados	\sum
Não	4.187	0	4.187
Sim	2	0	2
\sum	4.189	0	4.189

Amostragem + Dados populacionais

Ao invés de utilizar apenas o número de casos na amostra podemos tornar mais eficiente. . .

Além do teste, se soubermos o número de unidades na amostra que já foram consideradas caso anteriormente. . .

Função de verossimilhança

Para o problema acima temos $X \sim \text{Binomial}(n, \pi)$ e $Y|X \sim \text{Binomial}\left(X, \frac{\rho}{\pi}\right)$, assim a distribuição conjunta das variáveis é dada por

$$p(Y, X) = \pi^X (1 - \pi)^{1-X} \times (\rho/\pi)^Y [1 - (\rho/\pi)]^{X-Y}$$

Agora suponha que observamos uma amostra aleatória (simples) de tamanho n da população de interesse, $(\mathbf{y}, \mathbf{x}) = \{(y_1, x_1), \dots, (y_n, x_n)\}$. A distribuição conjunta de probabilidade pode ser dada por

$$L(\pi; \mathbf{y}, \mathbf{x}) = \binom{n}{n_x} \pi^{n_x} (1 - \pi)^{n - n_x} \times \binom{n_x}{n_y} (\rho/\pi)^{n_y} [1 - (\rho/\pi)]^{n_x - n_y}$$

Verossimilhança em termos de $\mu \dots$

$$L(\mu; \mathbf{y}, \mathbf{x}) = \binom{n}{n_x} \pi^{n_x} (1 - \pi)^{n - n_x} \times \binom{n_x}{n_y} (\rho/\pi)^{n_y} [1 - (\rho/\pi)]^{n_x - n_y}$$

- Isso é o mesmo que pós estratificação, raking e calibragem. . .

Referências

Estimating the proportion of Corona cases with a random sample

- <https://grazeconomics.wordpress.com/2020/04/22/estimating-the-proportion-of-corona-cases-with-a-random-sample/>